API avancée

ETag & Rate Limit

Entity Tag et contrôle de version

Entity Tag (ETag)

Un mécanisme permettant d'identifier la version d'une ressource.
Il est définit par la RFC 2616, section 3.11
Il sert d'identifiant pour les services de cache et permet donc de limiter l'utilisation de la bande passante.
Il permet aussi de prévenir les modifications simultanées d'une même ressource.

2 ressources différentes doivent avoir des ETag différents. L'ETag est un hash de la ressource.

Fonctionnement :

Le serveur communique un HEADER ***ETag: "hash"*** lorsqu'il fournit une ressource
Le client utilise un HEADER ***If-None-Match: "hash"*** ou ***If-Match: "hash"*** lorsqu'il demande une ressource

Exemple : Réduire l'utilisation de la bande passante

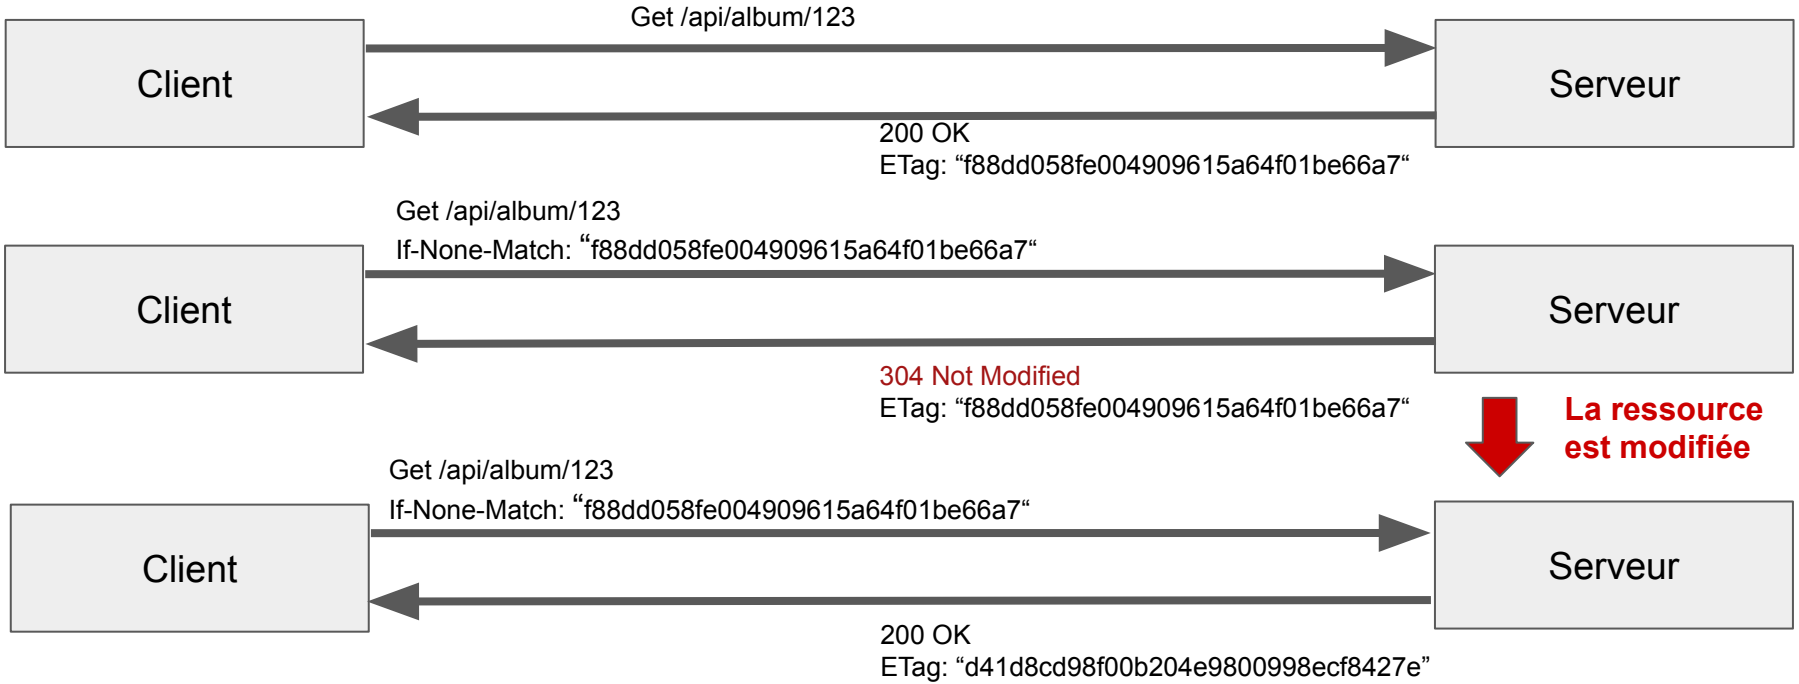

Exemple : Modifications simultanées

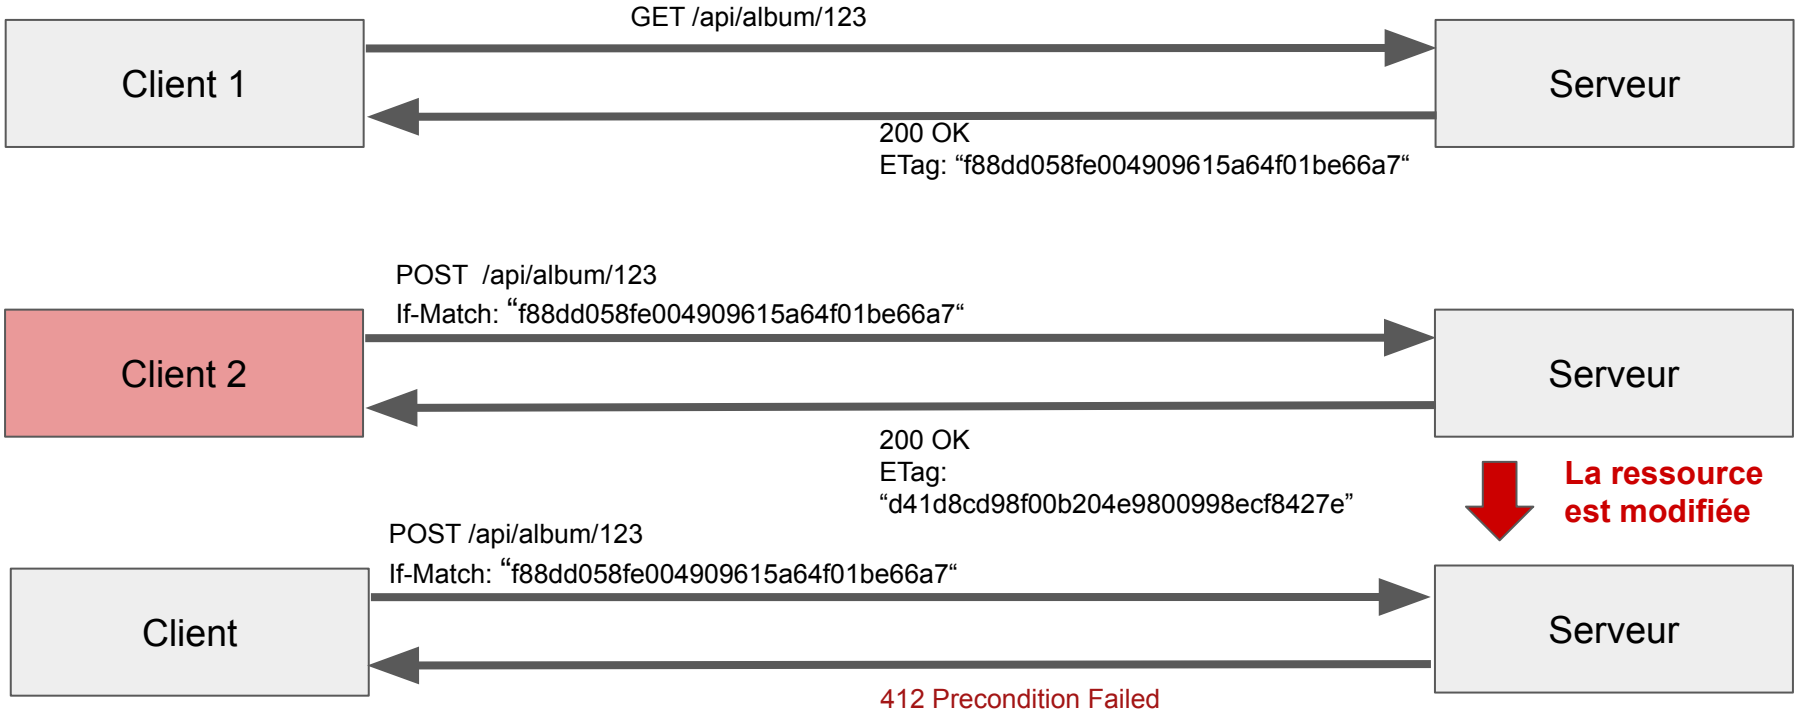

Strong / weak ETag

Définie dans la RFC 2616, section 13.3.3

Différencie 2 type de validation (forte et faible)

Forte :

Le validateur (l'ETag) change avec **chaque** changement de la ressource.

Souvent la valeur de hashage de notre entité.

La vérification est au bit près.

Faible :

Le validateur (l'ETag) change seulement lors de **changements sémantiques** de la ressource.

Préfixé par W/

Last-Modified est considéré par défaut comme une vérification faible.

ETag VS Last-Modified

Last-Modified est similaire à ETag bien que moins précis car uniquement basé sur la date de modification de la ressource.

Le client utilise un HEADER ***If-Modified-Since: Date*** ou ***If-Unmodified-Since: Date*** lorsqu'il demande une ressource.
Le serveur lui renvoie un HEADER ***Last-Modified: Date***

ex : Last-Modified: Wed, 21 Oct 2015 07:28:00 GMT

L'Etag est préférable au Last-Modified si un vérification forte est nécessaire (taux de modification supérieur à 1/s)

La recommandation de la RFC est d'utiliser les 2 si possible

Shallow Implementation - Spring

Spring propose ***ShallowEtagHeaderFilter*** pour gérer de manière transparente les ETag.

Mais comme son nom l'indique, il ne gère les ETags qu'en surface. Il calcule l'ETag d'une ressource à partir de la réponse du service, les calculs pour récupérer la ressource sont effectués dans tous les cas.

Ne fonctionne que pour les requêtes GET et la condition IF-NONE-MATCH

ETag sous la forme : 0 + hash MD5 sur 32bits

ex : *077c00bcab66658c79edccafdc17f2186*

Deep Implementation

Comment faire pour ne pas avoir à recalculer l'ETag à partir de la notre réponse

- S'assurer que nos ressources ne seront pas modifiées sans modification dans le cache

Mais pas de solution simple, cela va dépendre de vos ressources et de votre infrastructure, …

- Où placer le cache si on à une infrastructure distribué
- Problème de performance si on garde toutes nos ressources dans le cache
- Est-ce que c'est bien nécessaire ?

Rate Limit

Rate Limit

La limitation du débit consiste à empêcher la fréquence d’une opération de dépasser certaines contraintes.

- Se protéger contre une utilisation excessive (intentionnelle ou non) - DoS
- Limiter l'accès en fonction de règles commerciales

Si la limite est dépassée :

- Rejeter la requête → erreur 429 - Too Many Requests
- Mettre dans une file d’attente
- Surcharge financière

Techniques d’application

- Fixed window
  - Un nombre maximum de requêtes est fixé pour une fenêtre de temps fixe.
  - Si la limite est dépassé la requête est rejetée, il faudra attendre la prochaine fenêtre
  - Risque de pic de requêtes autour de la jonction entre deux fenêtres.

Techniques d’application

- Sliding window
  - Un nombre maximum de requêtes est fixé pour une fenêtre de temps fixe.
  - On calcule une valeur estimée du compteur à un instant t en pondérant la capacité de la fenêtre précédente avec la fenêtre actuelle.
  - Si la valeur estimé dépasse la limite, la requête est rejetée

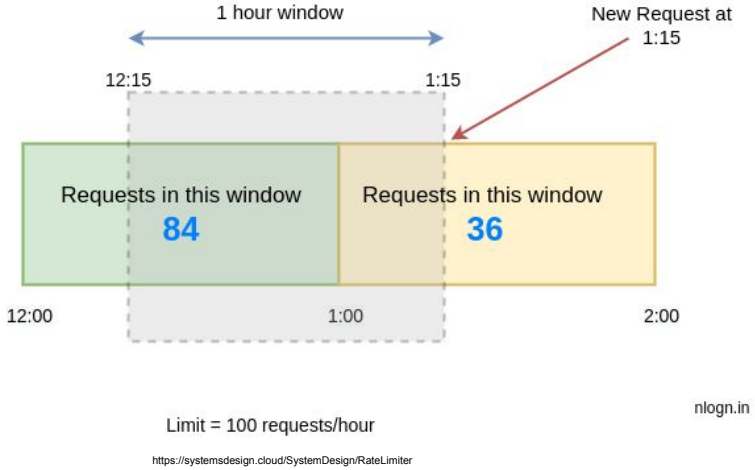

ce → Compteur estimé
xp → compteur précédent (84)
tf → taille de la fenêtre (60 minutes)
t → temps passé dans la fenêtre (15)
ca → compteur actuelle (36)

ce = cp * ((tf - t) / tf) + ca = 84 * 0.75 + 36 = 99

ce (99) < limite (100) ⇒ la requête est acceptée

Techniques d’application

- Token Bucket
  - Le seau d’une capacité fixe se **remplit à un rythme constant** et chaque requêtes consommes des jetons
  - Si le seau est vide, la requête est rejetée.

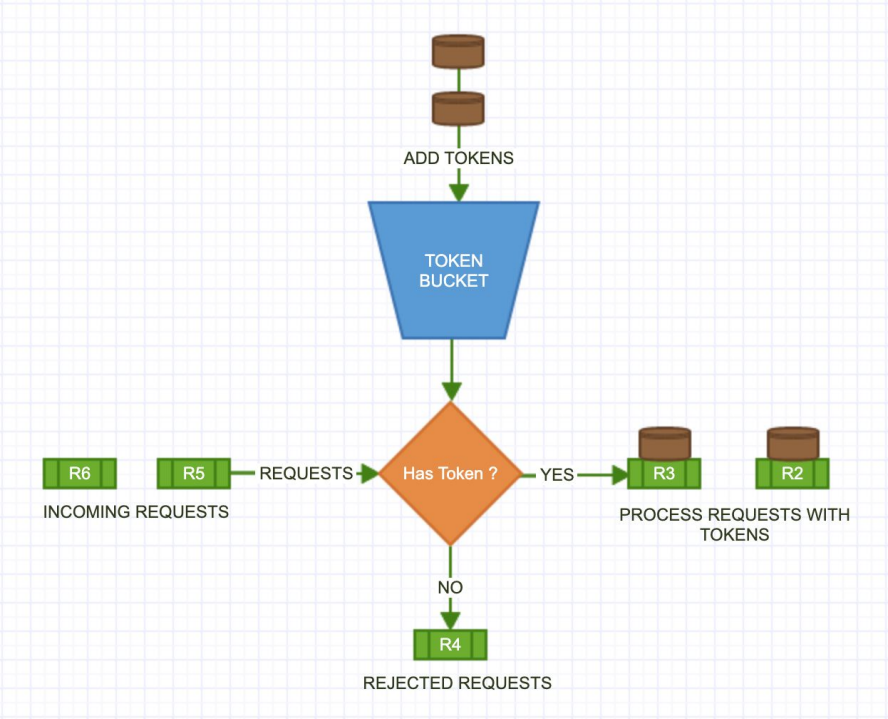

https://systemsdesign.cloud/SystemDesign/RateLimiter

Techniques d’application

- Leaky Bucket
  - Le sceau d’une capacité fixe se **vide à un rythme constant** (si il n’est pas vide), chaque requête remplit le seau.
  - Si le seau est plein, il déborde et la requête est rejetée
  - Lisser les pics de consommations
  - Le débit de requêtes traité est constant

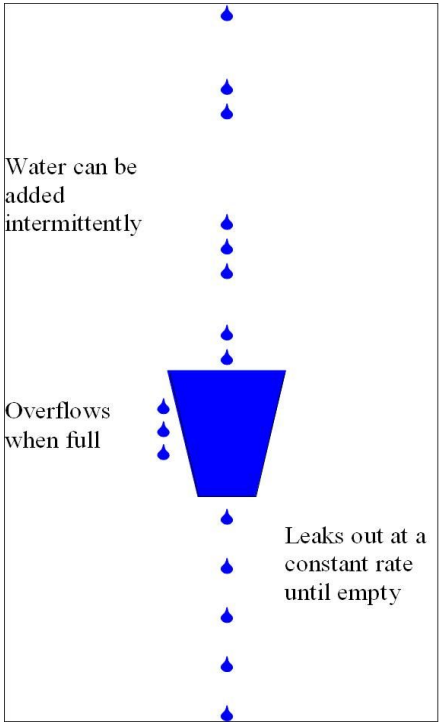

https://upload.wikimedia.org/wikipedia/commons/c/c4/Leaky_bucket_analogy.JPG

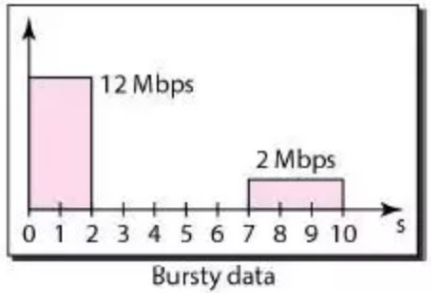

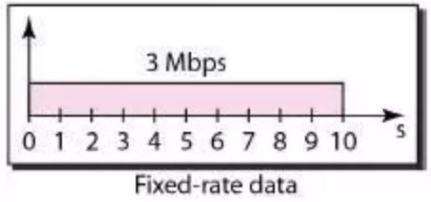

https://systemsdesign.cloud/SystemDesign/RateLimiter

Implementation Token Bucket - Bucket4j

Librairie bucket4j :

- Ajout de jetons toutes les *r* seconde dans le seau
- Le sceau à une capacité de *x* jetons
- Une requête consomme *n* jetons du seau

Terminologie :

- Bucket → représente le token bucket et fournit les méthodes pour interagir avec
- Bandwidth → représente la capacité du bucket
- Refill → représente le taux de remplissage du bucket

Bucket4j - Terminologie

Méthodes du Bucket :

- ***boolean tryConsume(long numTokens)*** //essaie de consommé x token
- ***ConsumptionProbe tryConsumeAndReturnRemaining(long numTokens)***

Méthodes de la ConsumptionProbe :

- ***boolean isConsumed()*** //donne le résultat de tentative d'utilisation des tokens
- ***long getRemainingTokens()*** // donne le nombre de tokens restant dans le bucket
- ***long getNanosToWaitForRefill()*** // 0 si isConsumed() == true sinon temps en nanosecondes avant que le nombre de tokens nécessaire soit ajouté au bucket

Bucket4j - configuration

import gradle :

```
implementation group: 'com.github.vladimir-bukhtoyarov' , name: 'bucket4j-core', version: '7.6.0'
```

Mise en place

```
//rajoute 10 tokens toutes les minutes
Refill refill = Refill.intervally(10, Duration.ofMinutes(1));
//capacité max de 10 token
Bandwidth limit = Bandwidth.classic(10, refill);
Bucket bucket = Bucket.builder().addLimit(limit).build();
```

Bucket4j - Utilisation basique

```
@GetMapping
public ResponseEntity<String> hello() {
    if(bucket.tryConsume(1)) {
        return ResponseEntity.ok("world");
    }
    return ResponseEntity.status(HttpStatus.TOO_MANY_REQUESTS).build();
}
```

Bucket4j - Informer le client

```java
@GetMapping
public ResponseEntity<String> hello() {
   ConsumptionProbe probe = bucket.tryConsumeAndReturnRemaining(1);
   if(probe.isConsumed()) {
       return ResponseEntity.ok()
               .header("X-Rate-Limit-Remaining", Long.toString(probe.getRemainingTokens()))
               .body("world");
   }
   long delaiEnSeconde = probe.getNanosToWaitForRefill() / 1_000_000_000;
   return ResponseEntity.status(HttpStatus.TOO_MANY_REQUESTS)
           .header("X-Rate-Limit-Retry-After-Seconds", String.valueOf(delaiEnSeconde))
           .build();
}
```

Bucket4j - Refill

- Greedy
  - Ajoute des tokens de manière le plus vite possible pour atteindre le max à la fin de l'interval
    - 10 tokens par 1 seconde, ajoute 1 token toutes les 100 ms
      - `Refill.greedy(10, Duration.ofSeconds(1));`
- Interval
  - Attend la fin de l'interval pour générer tous les tokens
    - `Refill.intervally(100, Duration.ofMinutes(1));`
- IntervallyAligned
  - Comme Iterval mais on peut lui configurer l'"Instant" du premier remplissage
    - `Instant firstRefillTime = ZonedDateTime.now()`
      `.truncatedTo(ChronoUnit.HOURS).plus(1, ChronoUnit.HOURS).toInstant();`
    - `Refill.intervallyAligned(400, Duration.ofHours(1), firstRefillTime, true);`

Bucket4j - Bandwidth

Une simple Bandwidth utilise un Refill “Greedy”

```
Bandwidth.simple(100, Duration.ofMinutes(1));
Bandwidth.classic(100, Refill.greedy(100, Duration.ofMinutes(1)));
```

On peut avoir une capacité différente de notre taux de remplissage pour limiter fréquence d’accès à l’API

```
long capaciteMax = 50;
Refill refill = Refill.greedy(10, Duration.ofSeconds(1));
Bandwidth limit = Bandwidth.classic(capaciteMax, refill);
Bucket.builder().addLimit(limit).build() ;
```

On peut également avoir définir plusieures Bandwidth

```
Bucket.builder()
        .addLimit(Bandwidth.simple(1000, Duration.ofMinutes(1)))// 1000 tokens par 1 minute
        .addLimit(Bandwidth.simple(50, Duration.ofSeconds(1)))// mais pas plus 50 tokens par 1 second
        .build() ;
```

Webographie

https://apisyouwonthate.com/blog/api-versioning-has-no-right-way

https://restfulapi.net/versioning/

https://datatracker.ietf.org/doc/html/rfc7231

https://www.youtube.com/watch?v=pIkA-aPtkNs

https://dzone.com/articles/versioning-rest-api-with-spring-boot-and-swagger

https://cloud.google.com/architecture/rate-limiting-strategies-techniques

https://en.wikipedia.org/wiki/Token_bucket

https://github.com/bucket4j/bucket4j/blob/master/README.md

https://systemsdesign.cloud/SystemDesign/RateLimiter

https://www.javadevjournal.com/spring/etags-for-rest-with-spring/

https://www.youtube.com/watch?v=pIkA-aPtkNs

https://bucket4j.com/8.1.1/toc.html#quick-start-examples